ELK STACK을 이용한 K-Culture 형태소 분석과 시각화 (K-pop과 K-movie를 중심으로)

1조 조원: 박두레, 신나정, 오재동, 홍훈표

목차

Part 1

ELK STACK과 트위터 API를 이용한 트위터 데이터 시각화 keyword: K-pop

Part 2

ELK STACK과 openAPI를 이용한 데이터 시각화 keyword: K-pop

Part 3

ELK STACK과 트위터 API를 이용한 데이터 시각화 keyword: K-movie

Part 1

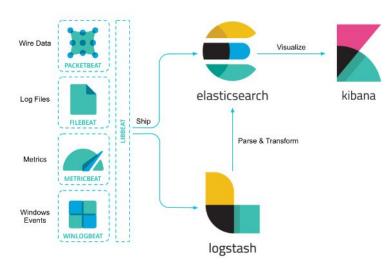
ELK STACK과 트위터 API를 이용한 트위터 데이터 시각화 keyword: K-pop

ELK STACK과 트위터 API를 이용한 트위터 데이터 수집

- Elasticsearch + Logstash + Kibana
- 트위터 API(Application Programming Interface)

Twitter API

Real-time access to the global conversation, right at your fingertips.



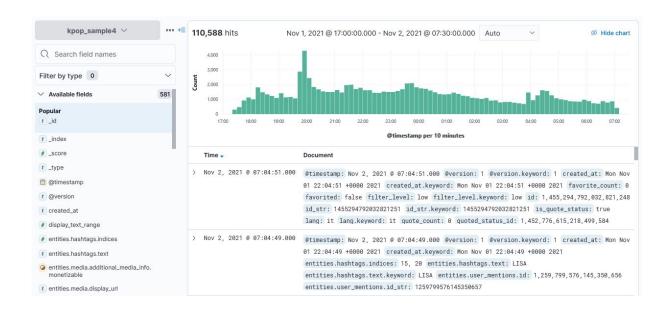
이미지 출처: https://www.seomse.com/posts/elk-stack/

트위터 API와 Logstash를 이용하여 데이터를 수집하는 방법

- K-Culture를 분석하고 시각화하기 위해 K-Culture의 하위 문화 중 하나인 K-pop을 분석 주제로 선택
- 트위터 API를 사용하기 위해 트위터 개발자 계정에서 발급 받은 API key 필요
- Logstash를 위한 config 파일 생성: logstash .conf
- 파일 실행: logstash.bat -f logstash_.conf
- 트위터 데이터를 실시간으로 Elasticsearch에서 수집 (keyword: kpop)
- Stack Management Index Patterns Create index pattern 에서 인덱스 선택 (index: kpop_sample)

```
input {
         twitter {
                  consumer_key => ""
                  consumer_secret => ""
                  oauth_token => ""
                  oauth_token_secret => ""
                  keywords => ["kpop"]
                  full_tweet => true
output {
         elasticsearch {
                  index => "kpop_sample"
```

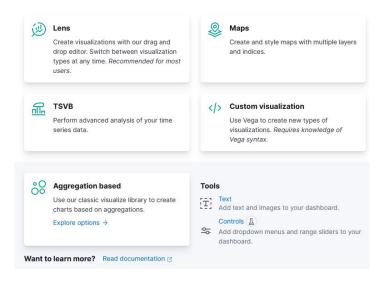
Discover



- Discover 메뉴에서 앞에서 설정한 키워드에 해당하는 트위터 데이터가 수집된 결과를 확인할 수 있음
 - 110,588 개의 데이터
 - 데이터 수집 시간: Nov 1, 2021 @ 17:00:00.000 ~ Nov 2, 2021 @ 07:30:00.000 (약 12시간)
 - 사용가능한 fields 등 확인 가능

Kibana를 이용한 시각화

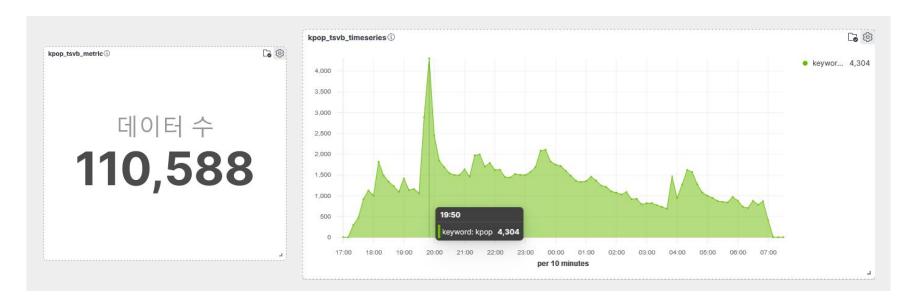
New visualization



kpop_fulltext_30_datetable	Data table	extended_tweet.full_text.keyword	datetable	
kpop_hashtags_10_bar_1	<u>Ihi</u> Vertical bar	entities.hashtags.text.keyword		
kpop_hashtags_15_bar_2	<u>∏</u> Vertical bar	entities.hashtags.text.keyword	bar	
kpop_hashtags_15_tag	Tag cloud	entities.hashtags.text.keyword	hashtag	
kpop_hashtags_20_bar	<u>In</u> Vertical bar	entities.hashtags.text.keyword	bar	
kpop_hashtags_30_pie	⊕ Pie	entities.hashtags.text.keyword	hashtag	
kpop_hashtags_50_datetable	Data table	entities.hashtags.text.keyword	datetable	
kpop_hashtags_50_tag		entities.hashtags.text.keyword	hashtag	
kpop_hashtags_5_line1	<u>⊬</u> Line	entities.hashtags.text.keyword	line	
kpop_hashtags_datetable1	Data table	entities.hashtags.text.keyword	datetable	
kpop_timestamp_histo1	国 Horizontal bar	timestamp	timestamp	
kpop_tsvb_metric	<u>⋒</u> TSVB	tsvb_timeseries	tsvb	
kpop_tsvb_timeseries	<u></u> TSVB	tsvb_timeseries	tsvb	

- Visualize Library - Create visualization에서 데이터 시각화

TSVB (Time Series Visual Builder)



Metric

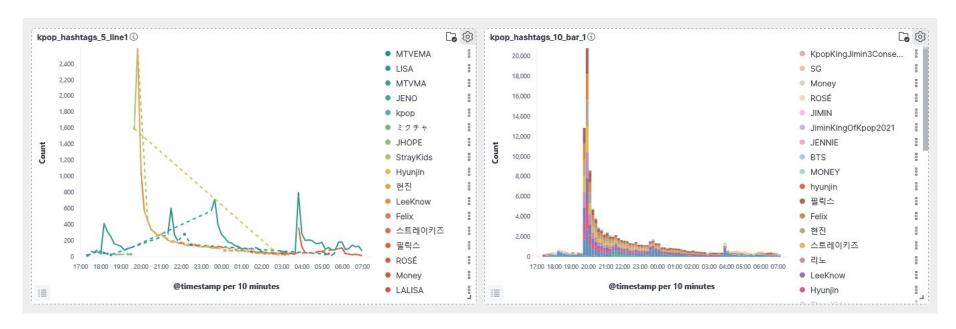
수집한 데이터의 수110,588 개

Time Series

- Nov 1, 2021 @ 17:00:00.000 ~ Nov 2, 2021 @ 07:30:00.000 사이에 keyword: kpop으로 수집한 시간별 데이터

차트 - 해시태그 시각화

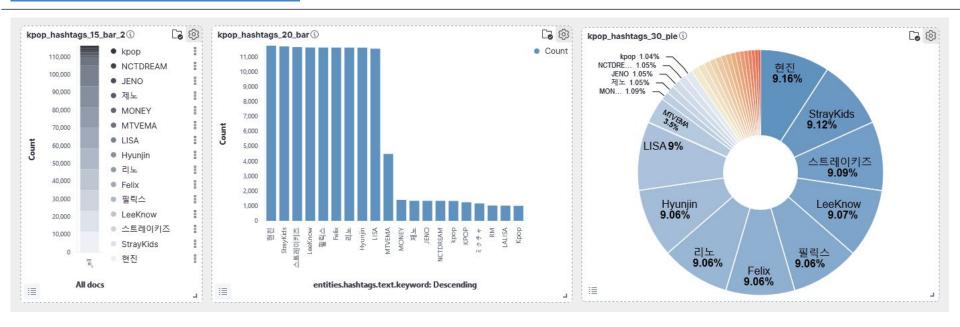
Line 그래프와 Vertical bar 그래프



- Y-axis: Count
- X-axis: timestamp per 10 minutes
 - Aggregation: Date Histogram
- Buckets: entities.hashtags.text.keyword
 - Sub aggregation: Terms

- 왼쪽: 시간별로 빈도수 상위 2개의 해시태그를 시간의 흐름에 따라 추적한 line 그래프
- 오른쪽: 시간별로 빈도수 상위 **10**개의 해시태그를 보여주는 **Vertical bar** 그래프

Vertical bar 그래프와 Pie 그래프



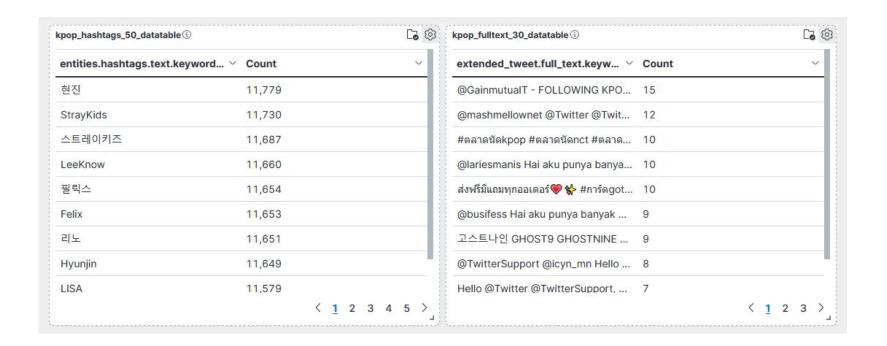
- 왼쪽: 빈도수 상위 15개의 해시태그를 한 개의 bar 그래프로 표현
- 가운데: 빈도수 상위 20개의 해시태그를 각각 bar 그래프로 표현
- 오른쪽: 빈도수 상위 30개의 해시태그를 보여주는 pie 그래프

JiminKingOfKpop2021 **KPOPATEEZ** Money 제노 AgustD ROSÉ STARSHIP นักดนตรีคลาสสิกฟังkpop **BLACKPINK PEPSIXSTARSHIP** 스타쉼뮤직콜라보

Hyunjin리노 스트레이키즈 필릭스현진Felix NCTDREAM StrayKidsLISA MONEY LeeKnow

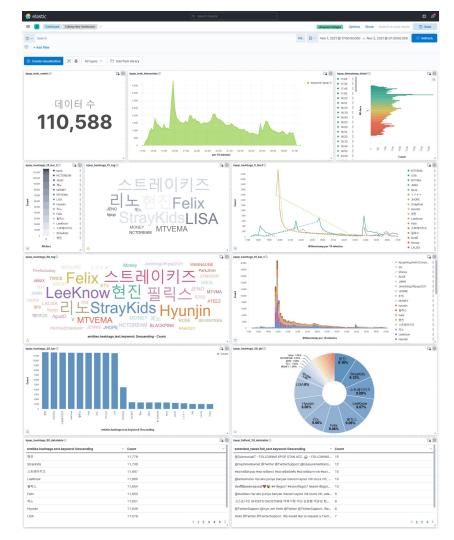
- 왼쪽: 빈도수 상위 50개의 해시태그를 나타낸 Tag cloud
- 위: 빈도수 상위 15개의 해시태그를 나타낸 Tag cloud

Data table



- 왼쪽: 빈도수 상위 50개의 해시태그에 대한 data table
- 오른쪽: 빈도수 상위 30개의 full_text에 대한 data table

Dashboard



ELK STACK과 트위터 API를 이용한 트위터 데이터 시각화: 중간 결론

- K-Culture를 분석하고 시각화하기 위해 K-Culture의 하위 문화 중 하나인 K-pop을 분석 주제로 선택
- Elasticsearch, Logstash, Kibana, Twitter API를 이용하여 트위터의 데이터를 실시간으로 수집하고 시각화
- 수집한 트위터 데이터 fields의 한계로 다양한 내용을 분석하지는 못함
- 데이터 Field 중 주로 해시태그(entities.hashtags.text.keyword)를 Kibana의 다양한 도구들을 이용하여 시각화
- Kibana의 TSVB의 Metric과 Time Series, Aggregation based의 Line, Vertical bar, Pie, Tag cloud, Data table 등의 시각화 도구 이용
- 수집한 트위터 데이터는 실시간 트렌드를 분석하기에는 적합하지만 이 연구에서 선택한 주제인 K-Culture에 대한 전반적인 분석에 사용하기에는 한계가 있음
- Twitter API를 이용하여 트위터의 데이터를 실시간으로 수집하고 Kibana의 다양한 도구를 활용했다는 것에 이 연구의 의의가 있음
- 이어지는 연구에서 다른 데이터를 이용하여 K-Culture에 대한 분석을 시도

Part 2

ELK STACK과 openAPI를 이용한 데이터 시각화 keyword: k-pop

국가 공공기관 데이터 활용

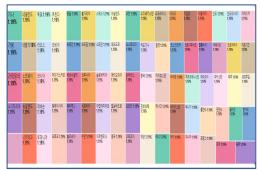
<공공데이터포털 API 이용>



<한국국제교류재단_분야 별



<시각화 예시>



<수집및 시각화 프로세스>



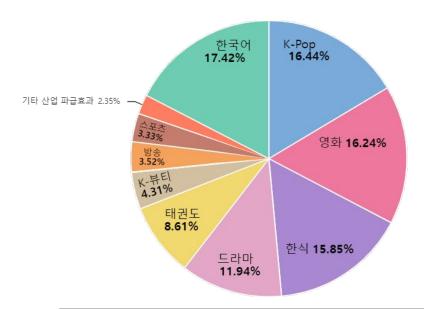






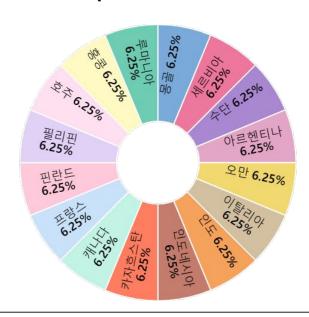
국외K- culture 관심분야 확인

<한국국제교류제단 분야별 한류데이터 분포>



문화 측면에서 영화나 한식, 드라마의 관심도가 비슷함 외적으로 한국어가 가장 많은 관심을 받음.

<k-Pop 관심 상위 10국가>



84개 국가 중 K-pop에 많은 관심을 가진 상위 국가는 16개 국가로 동아시아가 ¼ 이상을 차지. 서양에서도 관심을 고르게 가짐.

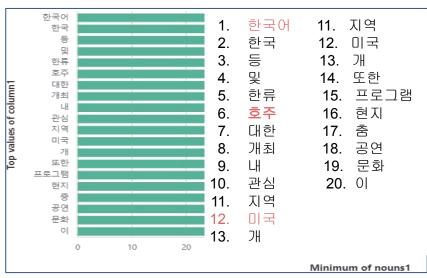
Konlp를 이용한 형태소 분석

<k-pop과 인기 검색어를 이용한 형태소 분석>



k-pop과 관련해 행사, 개최 공연 지역과 같은 단어들이 분포한 것으로 보아 k-pop 행사를 개최한 것이 상당히 긍정적인 평가를 받음을 확인할 수 있었음.

<k-pop과 관심 검색어를 이용한 형태소 분석 >



한국어에 대해 관련하여 가장 많은 관심을 가지고 있었으며, 호주나 미국에서 많은 관심을 가지고 있었음.

하국

인기

<elasticsearch를 이용한 형태소 분석 제언점>

<open_API와 twitter API 사용 차이 >



- elasticsearch를 이용해 쿼리를 통해 데이터를 필터링 하는것은 가능했으나 이어서 집계는 불가능

Top values of column1

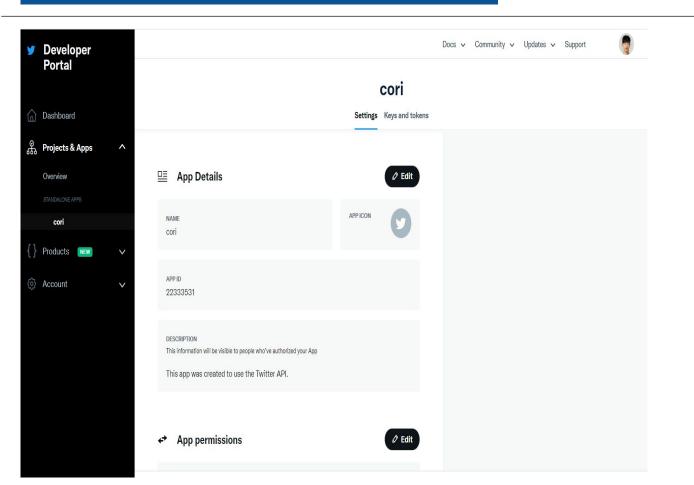
한류

- 파이썬의 konlpy를 통해 형태소 분석을 했으나 nori 한글 형태소 분석기보다는 정확도가 떨어짐
- 트위터의 데이터로는 k-pop에 대한 장점이나 강점에 대해 학술적으로 분석하기가 어려웠음
- twitter로는현재의 관심사를 확인하는데 용이
- · 학술적인 분석을 원한다면 SNS에서 데이터를 수집하는 것은 지양하는 것이 좋을듯함.

Part 3

ELK STACK과 twitterAPI를 이용한 데이터 시각화 keyword: k-movie

Twitter API Key를 이용한 데이터 수집



Twitter Developer 사이트 가입

애플리케이션 생성

API (Secret) Key, API (Secret) Token 발급

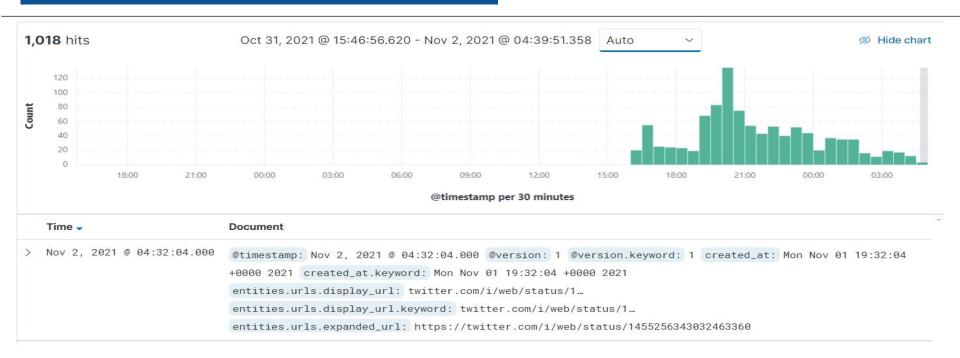
Twitter API Key를 이용한 데이터 수집

```
logstash-twitter - Windows 메모장
파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)
input{
         twitter{
                  consumer_key =>
                  consumer secret =>
                  oauth_token => "14
                                       korean movie 키워드 수집
                  oauth_token_secret
                  keywords => ["korean movie"]
                  full tweet => true
output{
         elasticsearch{
                  index => "kmovie_long"
```

logstash.conf 파일 수정

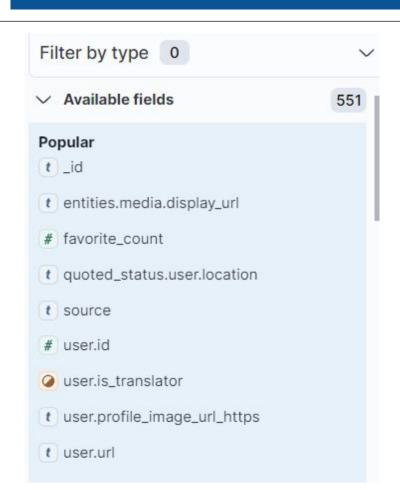
"url">"https://linktr.ee/blupdate2020, "screen.name">"SLUPDATE2020", "location">"?最級則판웰UY與디젲UNUTE2020", "location">"?"是數別報題UY與디젲UNUTE2020", "location">"?"是數別報題UY與디젲UNUTE2020", "location">""("location")" "'' "## State "location" "l

Twitter API Key를 이용한 데이터 수집



- Discover 메뉴에서 앞에서 설정한 키워드에 해당하는 트위터 데이터가 수집된 결과를 확인함
 - 1,018 개의 데이터
 - 데이터 수집 시간: Nov 1, 2021 @ 15:00:00.000 ~ Nov 2, 2021 @ 07:30:00.000
 - 사용가능한 fields 등 확인 가능

Twitter 수집 내용 분석 - 사용 컬럼



사용 가능한 컬럼은 500여개가 있지만, 실제로 쓸만한 데이터를 얻을 수 있는 컬럼이 거의 x

- 1. hastags.keywords
- 2. timestamp
- 3. language
- 4. user.locations
- 5. message

이외의 데이터 컬럼들은 대부분 분석 가치 x

Twitter 수집 내용 분석 결과 - Tag

hash-tag



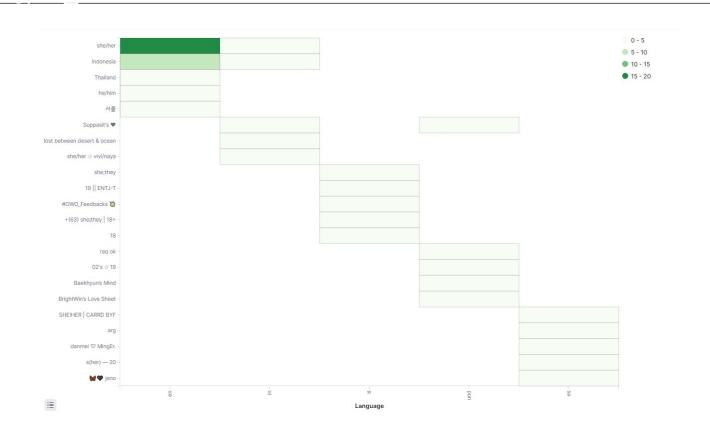
TamVazgeçimişken

- 1. JUNGKOOK
- 2. KimSeonHo
- 3. 김선호
- 4. SquidGame
- 5. SouthKorea

entities.hashtags.text.keyword: Descending - Count

최근 김선호와 정국이 많이 검색되고 있는 것을 확인할 수 있다.

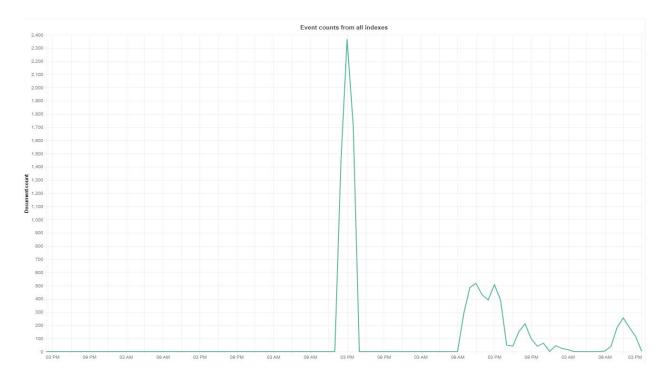
Twitter 수집 내용 분석 (문제점 1) - Location 및 Langauage



정확한 location x 사용자 지정 location o

ex) she/her, he/him, she, they, req ok 등

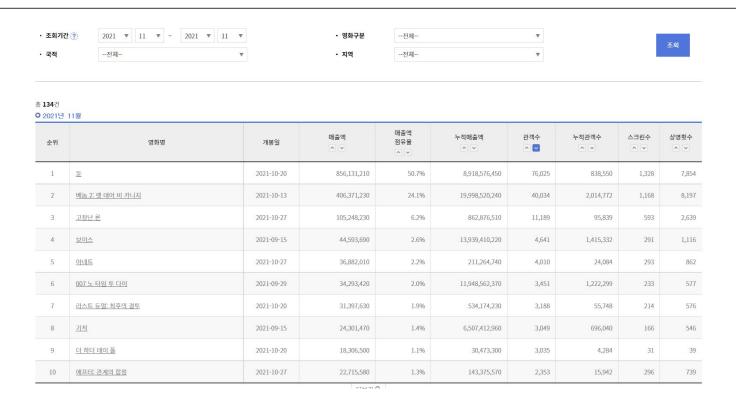
Twitter 수집 내용 분석 (문제점2) - 유의미한 Insight 얻기 힘듦



이와 같이 Twitter로부터 얻을 수 있는 정보가 많지 않아, 공공 데이터를 추가 탐색

특정 시간대에 'korean movie' 검색 빈도가 급증하였으며, 이에 대한 원인은 알 수 x

공공데이터 탐색 - 월별 박스오피스



2021년 10월 영화 랭킹 데이터를 사용하여 Kibana에서 분석 수행 순위, 영화명, 개봉일, 매출액, 관객 수, 스크린 수, 상영횟수 등이 있다.

공공데이터 전처리 - Null 데이터 삭제, 컬럼 추가

```
영화명
                                                                                                        배급사 상영정도
                                매출액 관객수 누적관객수 스크린수 상영횟수 대표국적
                 듄 2021-10-20 856005210 75999
                                             838,525
                                                              7842
                                                                      미국
                                                                                             워너브러더스 코리아(주)
                                                       1323
  베놈 2: 렛 데어 비 카니지 2021-10-13 406151230
                                            2.014.733
                                                       1168
                                                              8184
                                                                     미국 소니픽쳐스엔터테인먼트코리아주식회사극장배급지점
                                                                      미국
                                                                                    월트디즈니컴퍼니코리아 유한책임회사
             고장난론 2021-10-27 105181230
                                      11176
                                              95.826
                                                       593
                                                              2636
                                                                      하국
              보이스 2021-09-15
                                       4641
                                            1,415,332
                                                              1116
                                                                                                 (주)씨제이이엔엠
                                                       291
              아네트 2021-10-27 36882010
                                       4010
                                              24.084
                                                                    프랑스
                                                                                       그린나래미디어(주)주식회사 왓챠
                                                       293
                                                               862
for i in range(len(movie_data)):
   if movie_data['상영횟수 '][i] >= 0 and movie_data['상영횟수 '][i] < 2000:
      movie_data['상영정도'][i] = '매우 적음'
   elif movie_data['상영횟수 '][i] >= 2000 and movie_data['상영횟수 '][i] < 4000:
      movie data['상영정도'][i] = '적음'
   elif movie_data['상영횟수 '][i] >= 4000 and movie_data['상영횟수 '][i] < 6000:
      movie_data['상영정도'][i] = '보통'
   elif movie_data['상영횟수 '][i] >= 6000 and movie_data['상영횟수 '][i] < 8000:
      movie_data['상영정도'][i] = '많음'
   elif movie_data['상영횟수'][i] >= 8000:
      movie_data['상영정도'][i] = '매우 많음'
```

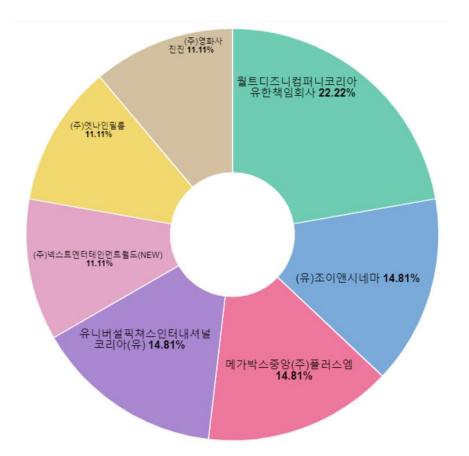
월별 상영횟수에 따라

movie data

매우 적음: 0 ~ 1999, 적음: 2000 ~ 3999, 4000 ~ 5999: 보통, 6000 ~ 7999: 많음

매우 많음: 8000 이상 으로 설정하여 컬럼 추가

공공데이터 분석 - 월별 박스 오피스, 배급사 분석



해당 공공 데이터를 사용하여 배급사를 분석해 본 결과,

- 1. 월트디즈니컴퍼니코리아
- 2. 조이엔시네마
- 3. 메가박스
- 4. 유니버셜 픽쳐서 인터네셔널 코리아

순으로 배급사 점유율을 확인

공공데이터 분석, 영화 제작년도 분석

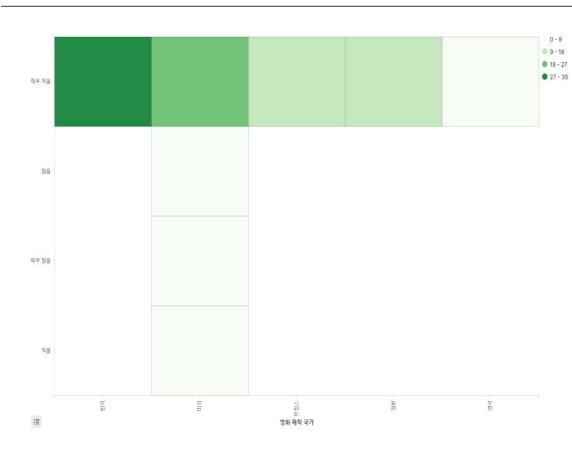


2021-09-01 - 개봉 영화 수 2021-10-01 - 개봉 영화 수

해당 공공 데이터를 사용하여 11월 랭킹 데이터의 영화 제작년도를 분석 해 본 결과, 2021년도 영화뿐만 아니라

오래된 영화 또한 꾸준히 사랑받고 있음을 확인

공공데이터 분석, 상영횟수와 제작 국가 분석



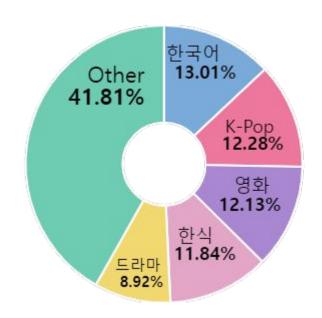
해당 공공 데이터를 사용하여 **11**월 랭킹 데이터의 영화 제작 국가와 상영횟수를 분석해 본 결과,

대부분의 월별 영화 상영 횟수는 2,000건 미만이었고 미국에서 제작한 영화의 경우 8,000건 이상 상영된 영화도 있었음을 확인

한국국제교류재단_한류현황 CSV

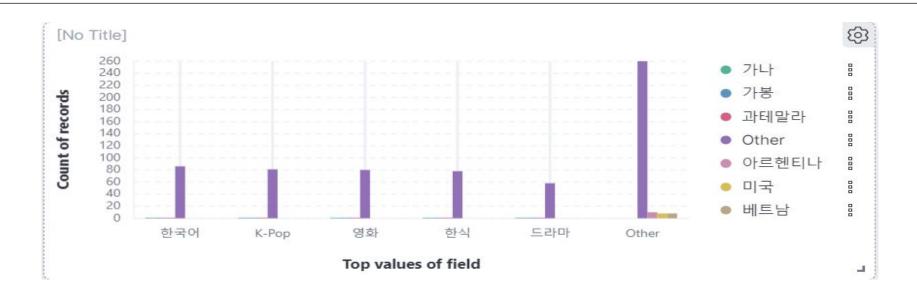
684

Count of records



- 한국 국제교류재단_한류현황 CSV 파일을 이용하여, _doc개수 684개의 데이터를 확인함
- 드라마 및 영화의 데이터가 20%이상을 차지함

분야별 한국에 관심이 많은 국가



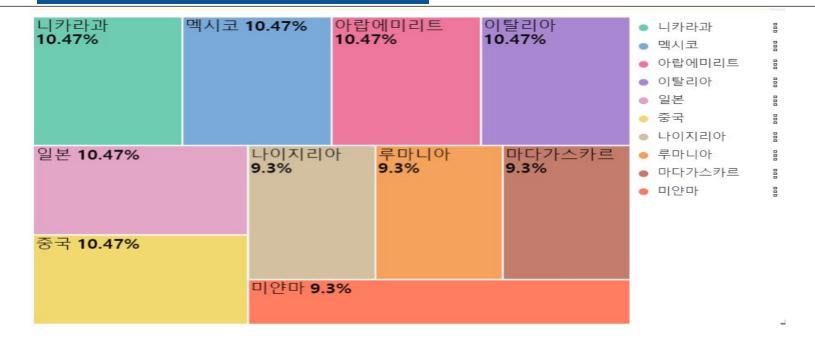
- 아르헨티나, 미국, 베트남 등의 국가가 한국어, K-pop, 한국 영화 분야에 관심이 많음
- Others에는 K-beauty, 스포츠(베트남 축구) 등에도 관심을 보이는 것으로 확인

한국 드라마에 관심이 많은 국가

스페인 1.71%	니카라과 1.54%	멕시코 1.54%	아랍에미리트 1.54 %	이탈리아 1.54 %	일본 1.54%	중국 1.54%	나이지리아 1.37%	루마니아 1.37 %	마다가스카르 1.37%
									,

- 한국 드라마에 관심이 많은 국가로는 스페인, 니카라과, 멕시코, 아랍에미리트 등의 국가 상위 순위를 차지
- 특히 아랍에미리트 국가에서는 과거에 <내 이름은 김삼순> <대장금> <미안하다 사랑한다> 등 국내 드라마를 방영해 높은 인기를 얻은 바가 있어, 한국 드라마에 대한 기대치가 높은 편임
- 또한 최근 한국 드라마를 리메이크한 터키 드라마(크즘(Kızım : 내 딸 서영이 리메이크작)들이 스페인 채널을 통해 방영되면서 원작인 한국 드라마에 대한 인기가 높음

한국 영화에 관심이 많은 국가



- 니카라과 국가는 매년 한국 영화제가 개최될 정도로 관심이 많음(특히 건축학개론, 마마, 은밀하게 위대하게)
 - 멕시코 국가는 민주화 과정에 대한 감성적 유사성이 있기 때문에 택시 운전사. 1987 등의 영화에 관심이 높음